

Rafaella Duarte

rafaella.d.d.carvalho@gmail.com | github.com/rafaelladuarte | linkedin.com/in/rafaella-duarte-carvalho

RESUMO

Engenheira de Dados com 3+ anos de experiência em pipelines ETL/ELT em produção nos setores jurídico e e-commerce, atuando em ambientes de alta escala (+200M registros, +20TB, +60M produtos). Experiência com Python, SQL Server, BigQuery, RabbitMQ e GCP, arquitetura medallion, ingestão via APIs, web scraping e mensageria assíncrona. Desenvolvimento de soluções com LLMs (RAG, embeddings) e OCR para extração estruturada e classificação semântica.

HABILIDADES

Linguagens & Processamento: Python, SQL, Bash, PySpark, Apache Spark

Engenharia de Dados: ETL/ELT, Data Pipelines, Data Warehouse, Data Lake, Arquitetura Medallion

Bancos & Cloud: PostgreSQL, SQL Server, MongoDB, Elasticsearch, GCP (BigQuery, Cloud Storage, Cloud Run, Cloud Functions), AWS (S3, Glue, Athena)

Ferramentas & Plataforma: Linux, Docker, Git, Airflow, dbt, Kafka, RabbitMQ, FastAPI

BI & IA: Power BI, RAG, Embeddings, OCR, LangChain, LLM APIs

EXPERIÊNCIAS

E-xyon — Engenheira de Dados

Jan 2025 – atual

- Desenvolve data pipelines para ingestão e processamento de dados não estruturados (OCR + LLMs) aplicados a documentos jurídicos, com parsing automatizado e persistência em MongoDB.
- Desenvolve pipeline de classificação semântica de causa raiz jurídica com arquitetura RAG (Retrieval-Augmented Generation), utilizando embeddings e LangChain para recuperação e estruturação de dados analíticos.
- Otimiza ambiente SQL Server (+20TB / 200M registros), realizando tuning de queries (CTEs, window functions), criação de procedures em T-SQL, execução de jobs batch e exposição de dados via APIs REST.
- Implementa data warehousing com pipelines ETL/ELT no GCP, arquitetura Medallion (Bronze, Silver, Gold), integrando APIs públicas e sistemas legados.

Flow2Go — Desenvolvedora Python ETL (Freelancer)

Jan 2024 – Dez 2024

- Desenvolveu de pipeline end-to-end de ingestão de dados jurídicos, incluindo web scraping resiliente (anti-bot), persistência em MongoDB e disponibilização via API REST (FastAPI) para consumo em produção.

Linx — Engenheira de Dados

Nov 2022 – Nov 2023

- Manteve e otimizou data pipelines de catálogo (+60M produtos), com ingestão em Amazon S3 e processamento em BigQuery.
- Desenvolveu arquitetura distribuída de scraping para +10 marketplaces, com processamento assíncrono via RabbitMQ (extração, processamento e enriquecimento de dados).
- Implementou camada de validação com Elasticsearch e BigQuery para detecção de anomalias estruturais.

Nodis (Grupo StoneCo) — Analista de Dados (Estágio)

Jan 2021 – Nov 2022

- Desenvolveu de pipelines ETL em Python integrados a PostgreSQL, MongoDB e Elasticsearch, além da criação de dashboards no Looker Studio para suporte à tomada de decisão.

FORMAÇÃO

PUC Minas — Especialização em Engenharia de Dados

2026 – 2028

UFU — Bacharelado em Ciências Econômicas

2019 – 2025

CERTIFICAÇÕES

Databricks - [Databricks Fundamentals](#) - 2026

Astronomer - [Apache Airflow 3 Fundamentals](#) - 2026

IDIOMAS

Inglês B1 — leitura técnica e comunicação escrita

Última Atualização: 01/05/2026